有限資料情境下旅遊需求預測之專家融合架構簡化復現

A Simplified Reproduction of Expert Fusion for Tourism Demand Forecasting

黃達 | 澳門城市大學 · 數據科學學院 | DDS001 | 2026 年 11 月

摘要（Abstract）

多源資訊融合能否穩定改善旅遊需求預測，取決於資料獨立性、發布時滯、預測期限及驗證程序。本研究以 Zou 等（2026）提出的 source-gated multi-source fusion（SG-MSF）為參照，利用 Eurostat tour_occ_nim 月度住宿夜數，對歐盟 27 國 2015–2025 年非居民住宿需求建立一套「三個 LightGBM 特徵族專家＋情境門控」的簡化架構，並與季節朴素、早期融合及等權組合比較。訓練採年度擴展窗口重訓，門控以 2022 年資料擬合、2023 年早停，2024–2025 年為最終測試；預測期限為 1、3、6 個月。

在各國 MASE 中位數指標上，H=1 的等權組合最低（0.396），H=3 的情境門控最低（0.398），而 H=6 的季節朴素最低（0.433）。以總住宿夜數加權的 WAPE 判斷，季節朴素在三個期限均更優，說明「中位數國家」與「總量」評估會產生不同結論。本實驗的兩組輔助特徵均來自同一 Eurostat 資料表，不構成原研究的六源融合，故只主張架構層面的可重跑試驗，不宣稱完整復現或普遍優勢。

關鍵詞：旅遊需求預測；LightGBM；專家融合；門控網路；MASE；時序外驗證

1. Introduction／緒論

1.1 研究背景與問題

旅遊需求時間序列通常兼有強烈季節性、疫情等結構變動，以及目的地差異。當政府或旅宿業者需要提前 1–6 個月安排人力、運能與住宿容量時，單一歷史序列雖能形成穩健基線，卻難以表達搜尋熱度、航空連通性、價格或氣候等外部訊號。深度學習與多模態方法可以容納更豐富的資訊，但在資料稀疏、來源更新頻率不一或異常年份，模型複雜性未必等同預測增益 [2–6]。

本研究不將「模型更複雜」視為預設勝利條件，而將可驗證的核心問題設為：在固定的資料口徑與時間切分下，專家分工及可學習門控是否比強基線帶來一致且可解釋的改善？

1.2 研究問題與研究貢獻

本研究提出三個可檢驗問題（research questions）：RQ1，固定預測期限及共同測試樣本後，情境門控相對季節朴素、早期融合與等權融合是否有穩定改善？RQ2，同一組模型在 1、3、6 個月預測期限下，表現排序會否改變？RQ3，若按國家中位數尺度化誤差及依總住宿夜數加權的誤差衡量，結論是否一致？

本作業的貢獻有三項。第一，整合課程 W03 文獻圖譜與 AT3 實際技術復現，使研究問題、方法與實驗指標對齊。第二，保存原始 Eurostat 工作簿、預處理資料、模型設定、逐國與逐期限結果、門控權重及可重跑程式，支持結果稽核。第三，對負面結果保持完整報告：情境門控僅於 H=3 的國家 MASE 中位數指標領先，並不在所有期限和指標下勝出。

1.3 研究範圍與復現定義

Zou 等 [1] 的 SG-MSF 使用歷史需求、數位吸引力、航空連通性、價格競爭力、住宿容量、氣候六個訊號族，並依照發布時點進行即時資訊對齊。本報告只使用既有 Eurostat 住宿夜數工作簿，拆出「歷史總量」、「酒店子類」、「其他住宿子類」三組特徵族。因此「multi-source」在本次試驗中只表示多特徵族與多個專家，不表示三套獨立資料來源。原文的 SHAP 競爭力診斷、區間預測及目的地分群均不在本次完成範圍。

W03 早期曾以 Law 等（2019）的 Macau2018 LSTM-attention 作為技術復現候選；至 2026 年 10 月 28 日的 AT3，依照方法相關性與可操作性改以 Zou 等的新研究作為架構參照。這是研究對象的明確調整，不應將兩套模型的數值混入同一實驗表。

1.4 報告結構與證據來源

第 2 節以研究問題、特徵表示與融合方式組織文獻；第 3 節描述資料口徑、時間截點、模型、門控與評估；第 4 節呈現由原始 AT3 專案輸出的定量結果；第 5 節分析負面結果、限制與延伸；最後總結。所有本研究結果均可追索至 repository 的 results/*.csv、logs/*.json 與 src/*.py。

證據層級	材料與性質	可主張事項
原始研究	Zou et al. (2026) [1]	六源 SG-MSF 的發表結果；不是本次跑出的數值
本次重跑材料	AT3 2026-10-28；原始 CSV／代碼	三特徵族簡化復現與各期限比較
課程前置工作	W03 literature map；W04–W10 Labs	方法脈絡與研究判斷；非本次預測模型測試

2. Related Work／相關研究

2.1 從統計基線到非線性旅遊需求模型

季節朴素方法利用同一季節的歷史觀測預測未來月份，在季節性強的旅遊資料上形成難以忽略的對照。傳統 ARIMA/SARIMAX 對趨勢與季節性有明確統計結構，但要引入大量搜尋或平台訊號時，特徵選擇及滯後辨識會變得繁瑣。Law 等 [2] 以澳門月度到訪量和搜尋強度指數建立深度學習預測器，將 LSTM 與注意力結合以吸收高維外部訊號；它啟發我們將「訊號是否有額外資訊」與「模型是否足夠複雜」分開考察。

Lemmel 等 [3] 在薩爾斯堡 32 個景點的每小時旅遊流預測中，比較多種 RNN 家族與 ARIMA，顯示細粒度資料及外生天氣、節慶訊號存在價值，但不同方法的收益、計算成本與失敗樣本不能只看平均值。其資料與預測單位和本研究不同，文獻結果不可直接與 Eurostat 國家級住宿夜數比高低。

2.2 稀疏時序、多模態與動態空間依賴

Diao 等 [4] 將時空 GAN 產生的虛擬樣本與 enhanced Transformer 連結，處理少量旅遊歷史與隨時間變動的跨地區依賴。Qin 等 [5] 則以社群平台轉化指數將博客、圖文與短視頻資訊連結至旅遊需求；Jiang 等 [6] 提出多模態時序的 fusion、alignment 和 transference 方法框架，提醒研究者區分原始文本／圖像表徵與已經聚合的結構化代理指數。

以上研究共同推動「外生資訊與動態關係」的研究方向，但資料粒度、訓練樣本量、訊號發布延遲和比較基線差異極大。因而不能從單一研究得出「額外模態必定改善旅遊預測」的普遍結論；若未控制來源可得時點，訊號數量越多反而可能增加資訊洩漏風險。

2.3 技術基礎：樹模型、專家混合與可比指標

LightGBM [7] 提供較低計算成本的梯度提升樹基學習器，適合用於含滯後、季節與類別特徵的表格時間序列。專家混合網路的模組化思想可追溯至 Jacobs 等 [8]：不同專家處理不同輸入子空間，門控機制決定組合比重。但若多個專家持有高度相似的資訊，其預測誤差可能高度相關，學習權重未必優於等權平均。

衡量方法同樣關鍵。Hyndman 與 Koehler [9] 討論多序列尺度化指標 MASE 的可比性；本研究同時報告 WAPE，以避免只用國家中位數掩蓋大市場的總量誤差。時間序列驗證須重視預測來源與實際可用資料 [11]，且顯著性應另以適當的預測比較檢定分析 [12]，本實驗並未完成後者。

2.4 SG-MSF 與本研究的定位

Zou 等 [1] 在 27 個歐盟目的地的月度非居民住宿夜數上，提出六源 LightGBM 專家、動態門控及競爭力診斷。他們報告 SG-MSF 的國家 MASE 中位數於 H=1/3/6 分別為 0.504／0.566／0.627；早期融合 LightGBM 為 0.563／0.539／0.568。原文並未主張每個期限均由門控勝出。基於可重現性與資料已備妥的條件，本研究縮減成三特徵族的最小架構，重點是核對實作、評估程序及適用邊界，而非驗證全部六源的功效。

研究	核心問題	方法與證據	與本實驗差別
Law et al. [2]	高維搜尋訊號	澳門／LSTM-attention	單目的地到訪量，非住宿夜數
Lemmel et al. [3]	細粒度小樣本	POI／RNN 對 ARIMA	每小時資料，非月度國家
Diao et al. [4]	稀疏及空間動態	GAN＋Transformer	生成樣本與動態圖，未在此實作
Qin et al. [5]	社群訊號轉化	傳播指數＋集成	本研究未接入社群資料
Jiang et al. [6]	跨模態方法分類	Fusion／Alignment／Transference	提供框架，不是數值基線
Zou et al. [1]	來源歸因與時間對齊	六源 LightGBM＋門控	本研究只保留三組同源特徵

表 1　相關研究的問題、證據與本次簡化復現的界線

2.5 文獻缺口與可檢驗假設

文獻對多源融合已有不少正向結果，但對「來源是否獨立」、「發布延遲」、「不同預測期限的指標衝突」需要更具體的受控比較。本研究提出工作假設 H1：學習式門控可在某些期限改善等權組合的國家中位數 MASE，但不一定跨期限穩定；H2：同源特徵族的新增資訊有限，難以保証長期勝出；H3：按目的地中位數和按總量加權評估可能給出不同排名。這些假設由本次試驗的可觀測數值作描述性回答，未進行統計顯著性檢定，因此不將之表述為推論層面的已證實結論。

研究設計刻意選擇可低成本部署的 LightGBM 專家，而不是另起一個影像或語言模型任務。課程中 W04–W10 已涵蓋影像分類、檢測、分割與部分 fixture-based NLP/VLM 實驗；它們建立研究操作素養，但不構成本文預測指標的資料來源，也不應被堆砌為同一組旅遊 forecasting experiment。

3. Method／方法

3.1 資料來源、單位與缺失值處理

資料使用 Eurostat [10] 官方資料集 tour_occ_nim（Nights spent at tourist accommodation establishments – monthly data）的先前下載版本，原始工作簿於 2026-10-23 取得，版本資訊記錄於 data/processed/data_provenance.txt。選取 EU27 個別國家、非本國居民（FOR）、數量單位（NR）、總住宿類別 I551-I553，以月度住宿夜數為預測目標。對照特徵族取同表中的酒店子類 I551 與其他住宿子類 I552_I553；兩者不是獨立外部資料。

2015 年 1 月至 2025 年 12 月共有 27 × 132＝3,564 個理論國家—月份目標單位，其中缺失 69 個（1.94%）；缺失依訓練 2015–2021、門控擬合 2022、門控早停 2023 分別為 50／9／10，最終測試 2024–2025 無目標值缺失。缺失標記不設為零，訓練或評估時剔除無真實標籤的行；來源特徵在對應截點前的歷史前綴內處理。

設定	本次實作	稽核檔
對象／目標	EU27，FOR，NR，I551-I553	data/processed/*
資料期間	2015-01 至 2025-12（建模）	run_summary.json
目標缺失	69 / 3,564 = 1.94%	data_quality_summary.csv
預測期限	H=1、3、6 個月	results/test_metrics.csv
測試	2024–2025，H1/3 各 648；H6 647	results/run_summary.json

表 2　資料設定與結果可追溯路徑

3.2 截點一致的特徵工程

每一筆預測依照其 forecasting origin 建立可用資訊截止點：在原始程式碼中 cutoff = origin − 2，反映兩個月的資訊發布延遲假設。模型只可讀取截止點及更早的 total、hotel、other 住宿資料，並據此計算滯後、歷史滾動均值、波動度及季節性參照；月份、國別編碼等靜態／日曆特徵亦同步使用。於截點之後才發布的真實資料不能用於填補該列特徵。

本實驗採用單一的兩個月發布延遲簡化設定，尚未依 Eurostat 每條子序列的實際發布日逐筆回放。因此它是明確的時間對齊假設，而非所有來源實際發布日的完整驗證。

3.2.1 可用歷史、切分與資料品質稽核

原始 CSV 留存自 2000-01 至 2026-08 的歷史資料，以便建立樣本開始前的季節滯後；正式建模與報告固定 2015-01 至 2025-12。所有三個 horizon 都使用相同國家—月份目標集合，只因可用預測值限制而於 H=6 共同比較樣本減一列。正式測試前另將 2022 的 945 行與 2023 的 942 行供門控擬合與早停，避免把最終測試期結果用於調整門控。

由於目標是國家級「過夜住宿夜數」，不能把數值解讀為唯一旅客人數；一位旅客多晚住宿會貢獻多個 night。這一統計口徑差異也是日後把結果轉移至澳門或廈門景區每日入園人次時必須處理的效度問題。

3.3 專家、融合基線與情境門控

對每個 $H \in \{1,3,6\}$ 分別訓練三個 LightGBM 專家：E_1 只看總量歷史／季節／日曆特徵；E_2 在 E_1 上加入酒店子序列的滯後特徵；E_3 在 E_1 上加入其他住宿子序列滯後特徵。所有專家採 LightGBM L1 目標，與原文 Huber 損失不同。以 E_1–E_3 的簡單算術平均為等權基線；早期融合則將特徵族拼接，單獨訓練另一個 LightGBM。

門控是一個 32→16 隱藏層的多層感知器，輸入 3 組正規化的專家預測、27 維國別 one-hot、12 維月份 one-hot、3 維 horizon one-hot、時間索引與歷史同比增長等，共 47 維。輸出 3 組 softmax 權重 w_k，預測形式為 $\hat{y}_gate = \Sigma_k\, w_k(x)\cdot\hat{y}_k(x)$，且 $\Sigma_k\, w_k=1$。這是情境依賴的加權平均，不等同於原文六源專家或因果貢獻分解。

3.4 訓練、驗證與時間外測試

專家採逐年擴展窗口重訓，每個測試年度／預測期限以當年一月推算的歷史標籤截止日擬合；同年度不逐月重訓。門控使用 2022 年跨期限預測作為擬合資料（945 行），2023 年作為早停／驗證資料（942 行），最佳 epoch 為 20。最終測試為 2024–2025 年，且每個模型在同一 H 的共同可評估樣本上比較。原始專案保留 logs/expanding_refit_audit.csv 與 gate_training_history.csv 作稽核。

此協議保留了前向時間切分與對來源截點的限制，但較原文的逐月重訓和 expanding-window out-of-fold 門控訓練簡單；因此所有性能數值屬於這個設計，而不能視為原論文的精確再現。

要素	Zou et al. [1]	本次簡化復現
來源	六種外生／內生訊號族	同一表三組住宿子序列
樹模型損失	Huber	L1
重訓頻率	逐月更新	逐年擴展重訓
門控訓練	2017–2021 OOF 預測	2022 訓練／2023 早停
額外分析	SHAP、區間、競爭力診斷	描述性預測與門控權重

表 3　已實作與未實作的關鍵差異（不構成逐項完全復現）

3.5 指標及匯總口徑

對國家 c，MASE_c 定義為測試期 MAE_c / d_c，其中 d_c 為該國 2015–2021 訓練期內、以前一年同月作季節朴素參照計算的平均絕對差。報告的 headline MASE 是 27 國各自 MASE_c 的中位數，不是先合併全部國家再計算的 MASE。$\text{WAPE}=100\times\Sigma|y-\hat{y}|/\Sigma|y|$，對住宿夜數規模大的國家賦予更大實際權重。另保存 MAE、RMSE 及各國個別指標。此兩個匯總尺度的差異是研究問題的一部分，不能互相取代。

4. Experiments／實驗結果

4.1 測試環境與模型設定

本節全部數字均來自 AT3 既有專案的 results/test_metrics.csv、run_summary.json 與 country_level_metrics.csv，不是據原論文表格轉錄。特徵面板跨三個 horizon 共 10,692 列；訓練與測試的每項輸出保留對應國別、預測月份及模型。評估範圍是同一 Eurostat 資料口徑下的時間外樣本，未做跨資料版本、跨目的地或外部來源增量試驗。

4.2 主要指標：各國 MASE 中位數

模型	H=1	H=3	H=6
Seasonal naive	0.433	0.433	0.433
Equal-weight experts	0.396	0.412	0.624
Early-fusion LightGBM	0.406	0.443	0.514
Context-gated fusion	0.439	0.398	0.658

表 4　本次簡化復現的國家 MASE 中位數（越低越好；H=1/3 n=648，H=6 n=647）

H=1：等權專家 0.396 最低，情境門控 0.439 反而略高於季節朴素 0.433。H=3：情境門控 0.398 最低，優於等權 0.412、季節朴素 0.433 及早期融合 0.443。H=6：季節朴素 0.433 最低，學習式組合的 0.514–0.658 均較差。因此門控的改善有期限依賴，不支援「動態門控全面勝出」的敘述。

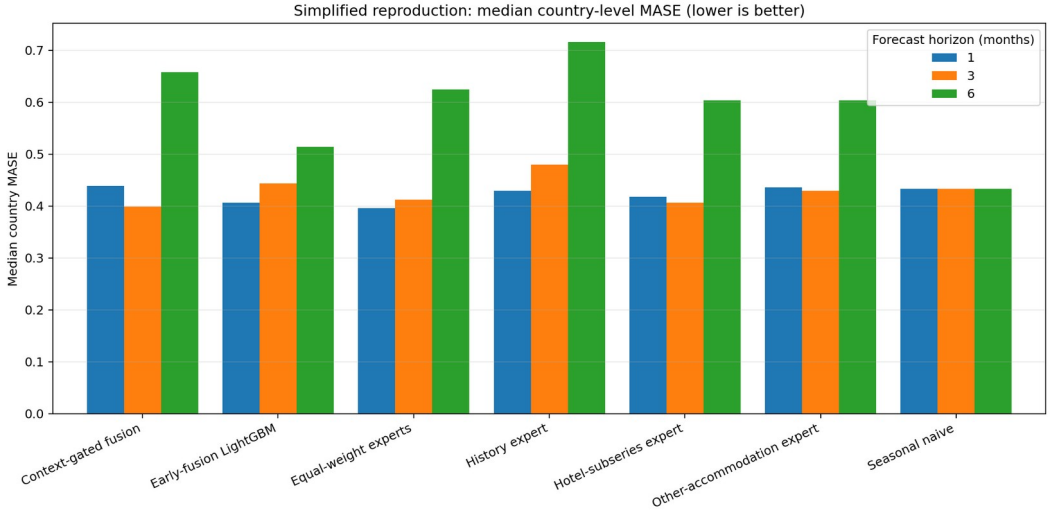


圖 1　各模型各期限的國家 MASE 中位數（AT3 原始實驗輸出）

4.3 指標敏感性：WAPE 與大規模目的地

若改以總住宿夜數加權的 WAPE 指標，季節朴素在 H=1/H=3/H=6 分別為 7.382%／7.382%／7.338%，均優於本次三種專家融合方案；情境門控相應為 8.322%／8.279%／11.279%。由於跨國 MASE 中位數重視典型國家，而 WAPE 對大市場的預測誤差更敏感，兩者可出現不同排序。這一點不能被「H=3 的 0.398」單獨掩蓋。

指標（WAPE，%）	H=1	H=3	H=6
Seasonal naive	7.382	7.382	7.338
Equal-weight experts	8.306	8.509	11.058
Early-fusion LightGBM	8.270	8.586	10.456
Context-gated fusion	8.322	8.279	11.279

表 5　住宿夜數總量加權誤差 WAPE（越低越好）

4.4 門控行為與可解釋性邊界

門控權重可顯示模型在不同 horizon 下相對偏向哪一組「特徵族專家」，但它並不能識別酒店或其他住宿變量對旅客需求的因果影響，更不能等同原文以 SHAP 聚合六個獨立來源後的目的地競爭力診斷。

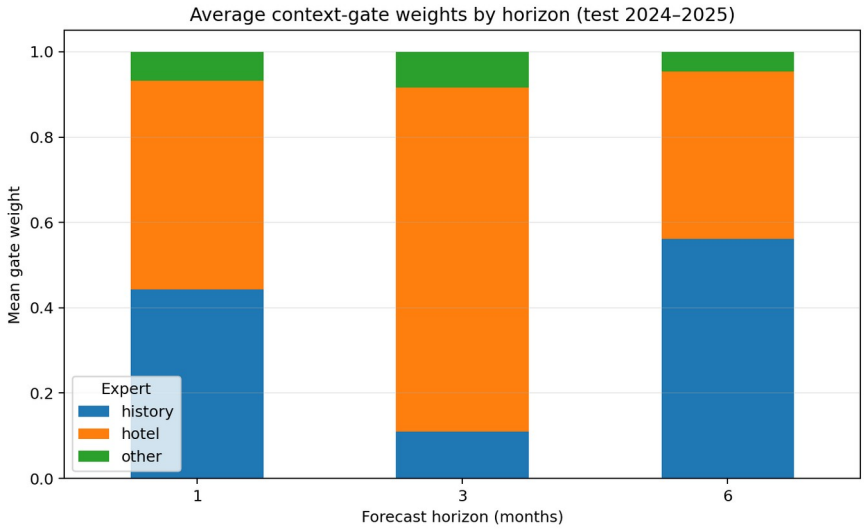


圖 2　測試期門控平均權重（原始專案輸出，非 SHAP 歸因）

4.5 個別國家診斷與結果範圍

原始專案另有德國、法國、義大利 H=1 的逐月真值與預測曲線（results/figures），可用來定位季節高峰及個別國家例外；但本報告不據三國圖像宣稱全部 27 國都出現相同模式。國別分析與所有原始逐月預測可在 country_level_metrics.csv 及 expanding_forecasts_2022_2025.csv 稽核。

5. Discussion／討論

5.1 為何較複雜的模型未必勝出？

第一，這個實作雖有三個專家，其實沒有獨立的搜尋、航空、價格或氣候訊號。酒店與其他住宿子序列和總住宿夜數存在結構性重疊，對預測誤差提供的新增資訊有限；三專家錯誤也可能高度相關。第二，門控的訓練期較短：2022 年受疫情後恢復與地區差異影響，2023 年作早停，對 2024–2025 年的可轉移性未獲保證。第三，H=6 時年度重訓與發布延遲使可用最新資料更少，簡單的季節模式反而可能較穩定。這些都是合理假說，仍需以增量消融或誤差相關分析進一步檢驗，不能當成已完成的因果解釋。

5.2 內部效度、外部效度與復現界線

內部效度方面，程式已依每列 cutoff 截斷來源，使用相同共同測試集，並留有重訓稽核，但仍未以真實資料發布日逐筆重放，也尚未獨立驗證全套特徵工程中的每個間接依賴。外部效度方面，樣本只涉及歐盟國家住宿夜數，不能直接推論澳門或廈門景點客流；不同資料頻率、疫情背景、入境政策與營運口徑均可能改變結果。

本次沒有正式的顯著性檢定、預測區間、模型參數敏感性或多種隨機種子的重複試驗，因此 H=3 門控相較等權 0.014 的 MASE 差距只能作描述性結果。原文 H=1/3/6 的 SG-MSF 0.504/0.566/0.627 只是文獻參照，因特徵來源、插補、損失與重訓頻率不同，不能與本次 0.439/0.398/0.658 直接相減並稱「性能提升」。

5.3 下一步：最小獨立來源增量

後續優先加入一組真正獨立且按月公開的航空客運或 HICP 價格指數，以來源發布日設定可核對的 lag，固定其餘切分與模型，對比「歷史需求→同源子類→新增外部來源」三層增量。再評估門控對多個 random seed 的穩定性、逐國誤差、預測期限與顯著性檢定。若此基礎成立，才適合拓展至澳門／廈門的節假日、氣象、社群與空間關係。

6. Conclusion／結論

在 27 國、三個預測期限的可重跑架構試驗中，情境門控於 H=3 的國家 MASE 中位數最佳（0.398），H=1 由等權專家最佳（0.396），H=6 由季節朴素最佳（0.433）；WAPE 則由季節朴素在三個期限均領先。因此研究支持「門控效果依賴期限與評估口徑」，而不支持複雜融合必然提升預測。研究的主要價值是透明的資料與時間切分、可稽核的負面結果，以及清楚劃分簡化架構復現與完整六源復現。

References／參考文獻

[1] Zou, L., Zhai, M., Zhang, J., & Liu, L. (2026). Interpretable multi-source feature fusion for tourism demand forecasting with destination competitiveness diagnostics. Systems and Soft Computing, 9, 200665. https://doi.org/10.1016/j.sasc.2026.200665

[2] Law, R., Li, G., Fong, D. K. C., & Han, X. (2019). Tourism demand forecasting: A deep learning approach. Annals of Tourism Research, 75, 410–423. https://doi.org/10.1016/j.annals.2019.01.014

[3] Lemmel, J., Babaiee, Z., Kleinlehner, M., et al. (2022). Deep-learning vs regression: Prediction of tourism flow with limited data. IJCAI Workshop AI4TS. https://arxiv.org/abs/2206.13274

[4] Diao, T., Wu, X., Yang, L., Xiao, L., & Dong, Y. (2025). A novel forecasting framework combining virtual samples and enhanced Transformer models for tourism demand forecasting. arXiv:2503.19423. https://arxiv.org/abs/2503.19423

[5] Qin, F., Bi, J.-W., Li, H., & Xu, H. (2025). Tourism demand forecasting using social media data: A deep learning-based ensemble model with social media communication conversion rates. Annals of Tourism Research, 115, 104058. https://doi.org/10.1016/j.annals.2025.104058

[6] Jiang, Y., Ning, K., Pan, Z., et al. (2025). Multi-modal time series analysis: A tutorial and survey. KDD 2025, 6043–6053. https://doi.org/10.1145/3711896.3736567

[7] Ke, G., Meng, Q., Finley, T., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems, 30. https://proceedings.neurips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html

[8] Jacobs, R. A., Jordan, M. I., Nowlan, S. J., & Hinton, G. E. (1991). Adaptive mixtures of local experts. Neural Computation, 3(1), 79–87. https://doi.org/10.1162/neco.1991.3.1.79

[9] Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. International Journal of Forecasting, 22(4), 679–688. https://doi.org/10.1016/j.ijforecast.2006.03.001

[10] Eurostat. (2026). Nights spent at tourist accommodation establishments — monthly data (tour_occ_nim). Statistical dataset. https://doi.org/10.2908/tour_occ_nim

[11] Bergmeir, C., Hyndman, R. J., & Koo, B. (2018). A note on the validity of cross-validation for evaluating autoregressive time series prediction. Computational Statistics & Data Analysis, 120, 70–83. https://doi.org/10.1016/j.csda.2017.11.003

[12] Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. Journal of Business & Economic Statistics, 13(3), 253–263. https://doi.org/10.1080/07350015.1995.10524599

程式與資料可復現聲明

隨附 GitHub-ready repository 包含 src/、data/、results/、logs/、figures/、requirements.txt、README.md 及 paper.pdf。結果為 2026-10-28 AT3 原始專案既有實驗，並已對其 CSV 統計和工件完整性做離線查核；本次 AT4 編修不冒稱重新訓練。重新執行所需環境與命令見 README。